

02/06/2026



UET

Dataset: Dự đoán giao dịch thương mại điện tử bằng cách sử dụng phân tích hành vi người tiêu dùng.

Liệu các đặc điểm hành vi trực tuyến và bối cảnh truy cập có thể dự báo chính xác khả năng mua của khách hàng hay không?

TRÌNH BÀY BỞI

24021549 - Doãn Duy Lợi

24021629 - Nguyễn Phúc Thành

24021605 - Nguyễn Minh Quân

https://docs.google.com/document/d/1r_hacXCp5zwc_v5E69ZD6czLfREZQWwEobHFGJQGv38M/edit?tab=t.0

Chương trình

- 1** Mục tiêu
- 2** Câu hỏi nghiên cứu
- 3** Phương pháp

- 4** Kết quả
- 5** Kết luận

1. Mục tiêu

- Đề tài tập trung vào việc phân tích hành vi truy cập website thương mại điện tử và dự đoán khả năng khách hàng có phát sinh giao dịch mua hàng hay không.
- Trong thương mại điện tử, không phải mọi khách truy cập website đều mua hàng. Việc nhận biết sớm nhóm khách hàng có khả năng mua giúp doanh nghiệp: Tối ưu chiến dịch marketing, Cá nhân hóa nội dung hiển thị, Gợi ý sản phẩm hoặc ưu đãi phù hợp, Tăng tỷ lệ chuyển đổi từ truy cập thành mua hàng, Giảm chi phí tiếp thị cho nhóm khách hàng ít tiềm năng.
- Đối tượng phân tích là các phiên truy cập của người dùng trên website thương mại điện tử.
- Mục tiêu tổng quát của báo cáo là phân tích các yếu tố ảnh hưởng đến hành vi mua hàng của khách truy cập website thương mại điện tử và xây dựng mô hình dự đoán khả năng phát sinh doanh thu từ một phiên truy cập.



2. Câu hỏi nghiên cứu

2.1. Câu hỏi nghiên cứu chính



Liệu các đặc điểm hành vi trực tuyến và bối cảnh truy cập có thể dự báo chính xác xác suất chuyển đổi của khách hàng hay không

2.2. Câu hỏi nghiên cứu phụ

Để trả lời câu hỏi chính, báo cáo tập trung vào các câu hỏi phụ sau:


Câu hỏi 1: Tỷ lệ phiên truy cập có phát sinh doanh thu là bao nhiêu?

Câu hỏi 2: Những biến nào ảnh hưởng mạnh nhất đến khả năng mua hàng?

Câu hỏi 3: Khách truy cập mới và khách truy cập quay lại có sự khác biệt về tỷ lệ mua hàng không?

Câu hỏi 4: Thời điểm truy cập theo tháng có ảnh hưởng đến khả năng mua hàng không?

Câu hỏi 5: Mô hình học máy nào cho kết quả dự đoán tốt nhất trên dataset này?



2.3. Kiểu bài toán

- Đây là bài toán phân loại nhị phân.
- Biến mục tiêu là Revenue: **0** (Không mua hàng) và **1** (Có mua hàng)






3. Phương pháp

3.1. Thu thập dữ liệu



- Nguồn dữ liệu: [Kaggle — Online Shoppers Purchasing Intention Dataset](#)
- Quy mô: 12.330 phiên truy cập, 18 thuộc tính
- Mục tiêu: Dự đoán khách hàng có mua hàng hay không qua biến Revenue.

	Tên thuộc tính	Kiểu dữ liệu	Mô tả
0	Administrative	int64	Số lượng trang quản trị mà người dùng đã truy cập
1	Administrative_Duration	float64	Tổng thời gian người dùng ở các trang quản trị
2	Informational	int64	Số lượng trang thông tin mà người dùng đã truy...
3	Informational_Duration	float64	Tổng thời gian người dùng ở các trang thông tin
4	ProductRelated	int64	Số lượng trang sản phẩm mà người dùng đã truy cập
5	ProductRelated_Duration	float64	Tổng thời gian người dùng ở các trang sản phẩm
6	BounceRates	float64	Tỉ lệ thoát ngay sau khi vào trang
7	ExitRates	float64	Tỉ lệ rời khỏi website tại một trang
8	PageValues	float64	Giá trị trung bình của các trang trước khi mua...
9	SpecialDay	float64	Ngày đặc biệt gần với phiên truy cập
10	Month	str	Tháng truy cập website
11	OperatingSystems	int64	Hệ điều hành của người dùng
12	Browser	int64	Trình duyệt của người dùng
13	Region	int64	Khu vực địa lý của người dùng
14	TrafficType	int64	Loại lưu lượng truy cập
15	VisitorType	str	Loại khách truy cập
16	Weekend	bool	Có phải cuối tuần hay không
17	Revenue	bool	Khách hàng có mua hàng hay không

3.2. Phân tích khám phá dữ liệu



3.3. Mô hình/Phân tích chính



Decision Tree dự đoán đúng:

- Không mua hàng: 1957
- Có mua hàng: 245

Gradient Boosting dự đoán đúng:

- Không mua hàng: 1970
- Có mua hàng: 243

Dựa trên ma trận nhầm lẫn, **Gradient Boosting** dự đoán nhóm không mua hàng tốt hơn **Decision Tree**, với 1970 trường hợp dự đoán đúng so với 1957 của **Decision Tree**. Tuy nhiên, đối với nhóm có mua hàng, **Decision Tree** dự đoán đúng 245 trường hợp, cao hơn một chút so với **Gradient Boosting** là 243 trường

4 Kết quả

4.1 Khám phá Hành vi: Khách mới & Tính mùa vụ




 Nghịch lý Khách hàng: Khách hàng mới (New Visitor) có tỷ lệ chốt đơn ấn tượng 24.91%, cao gấp đôi khách hàng cũ (13.93%).

 Đỉnh cao Tháng 11: Tỷ lệ chuyển đổi đạt kỷ lục 25.35% (tỉ lệ 1:4) nhờ các chiến dịch siêu sale (Black Friday).

 Hiện tượng Tháng 5: Lưu lượng truy cập cao nhất nhưng tỷ lệ mua hàng thấp (10.85%), chủ yếu là hành vi "xem dạo".

Insight Kinh doanh

Dồn lực tài nguyên và Remarketing vào tháng 11; tối ưu hóa trải nghiệm đầu tiên (First-time experience) để giữ chân nhóm khách hàng mới.



4.2 Hiệu suất Mô hình & Lựa chọn Thuật toán

So sánh 3 thuật toán học máy phân loại trên tập dữ liệu mất cân bằng (Target: Revenue). Chỉ số F1-Score và Recall được ưu tiên để tránh bỏ sót khách tiềm năng.

Mô hình dự báo	Accuracy	Prescision	Recall (nhãn 1)	F1-Score	AUC
Gradient Boosting (Chọn)	90.19%	0.73	0.59	0.65	0.925
Random Forest	90.00%	0.73	0.54	0.62	0.920
Logistic Regression	88.00%	0.74	0.37	0.49	0.890

Tại sao chọn Gradient Boosting?


Khả năng "học từ sai lầm" giúp mô hình tinh anh hơn

Giá trị Kinh doanh

Chỉ số AUC 0.925 chứng minh khả năng phân tách

4.3 Các yếu tố quyết định Ý định Mua hàng

Mức độ ảnh hưởng của các thuộc tính (Importance Score)



* Trích xuất từ mô hình Gradient Boosting

Chiến lược Hành động

- **Tập trung PageValues:** Ưu tiên điều hướng khách hàng vào các trang có giá trị tích lũy cao để tăng xác suất chốt đơn.
- **Kiểm soát BounceRates:** Tỷ lệ thoát trang là rào cản lớn nhất. Cần tối ưu tốc độ load và nội dung để giữ chân người dùng.
- **Cá nhân hóa theo mùa:** Tận dụng "Tháng vàng" để áp dụng các chiến dịch Retargeting mạnh mẽ.

5. Kết Luận

Qua phân tích dữ liệu hành vi truy cập website thương mại điện tử, có thể thấy các yếu tố như **PageValues**, **BounceRates**, **ProductRelated_Duration**, **Month** và **VisitorType** có ảnh hưởng rõ ràng đến khả năng mua hàng của khách hàng.

Kết quả chính:

- **PageValues** là biến quan trọng nhất, cho thấy các phiên truy cập đi qua trang có giá trị cao thường có khả năng mua hàng lớn hơn.
- **New Visitor** có tỷ lệ chuyển đổi cao hơn Returning Visitor.
- **Tháng 11** là thời điểm có tỷ lệ mua hàng cao, phù hợp với các chiến dịch mua sắm lớn.
- **BounceRates** càng cao thì khả năng mua hàng càng giảm.

Về mô hình dự đoán, **Gradient Boosting** là mô hình phù hợp nhất, đạt Accuracy khoảng 90.19%, Recall nhãn “Có mua hàng” đạt 0.59 và F1-score đạt 0.65. Mô hình này hỗ trợ nhận diện nhóm khách hàng có khả năng mua hàng tốt hơn trong điều kiện dữ liệu mất cân bằng.

Ý nghĩa thực tiễn:

- Doanh nghiệp có thể ưu tiên chăm sóc khách hàng mới, tăng khuyến mãi vào tháng 11, cải thiện trải nghiệm website để giảm **BounceRates**, đồng thời ứng dụng mô hình dự đoán để xác định sớm khách hàng tiềm năng.

Hạn chế và hướng phát triển:

- Dữ liệu còn thiếu thông tin cá nhân, lịch sử mua hàng dài hạn và các yếu tố bên ngoài. Nghiên cứu tiếp theo có thể bổ sung dữ liệu khách hàng, thử nghiệm các mô hình như **XGBoost**, **LightGBM** và áp dụng kỹ thuật xử lý mất cân bằng dữ liệu như **SMOTE**.